

Modelagem Comparativa de Séries Temporais com Variáveis Externas

1. Finalidade

Cada grupo deverá investigar cinco bases comuns, aplicar modelos estatísticos e de Machine Learning e produzir uma comparação crítica dos resultados obtidos.

2. Objetivos

- Documentar e explorar séries temporais com variáveis externas.
- Aplicar decomposição STL e interpretar tendência, sazonalidade e componente residual.
- Realizar Feature Engineering sem utilizar informações indisponíveis na data da previsão.
- Ajustar e comparar SARIMAX, Holt-Winters, Random Forest e um modelo adicional.
- Pesquisar e aplicar estratégias de otimização de hiperparâmetros.
- Avaliar os modelos por MAE utilizando validação walk-forward.
- Analisar os resíduos por métodos estatísticos e gráficos.
- Investigar a importância das features por um método compatível com cada modelo.
- Comunicar os resultados em relatório técnico, apresentação oral e registro de gestão do grupo.

3. Organização dos grupos e modelos

A turma será organizada em cinco grupos. Todos utilizarão as mesmas cinco bases e executarão os três modelos comuns, além de um modelo de especialização exclusivo. Cada grupo realizará 20 combinações principais: cinco bases multiplicadas por quatro modelos.

Grupo	Modelo de especialização	Família
1	XGBoost Regressor	Boosting baseado em árvores
2	Support Vector Regression (SVR)	Regressão baseada em margem
3	Elastic Net	Regressão linear regularizada
4	MLP Regressor	Rede neural artificial
5	PLS Regression	Regressão por componentes supervisionados

Os três modelos comuns a todos os grupos serão SARIMAX, Holt-Winters e Random Forest. O Holt-Winters deverá ser tratado como referência univariada, pois não utiliza variáveis externas. SARIMAX, Random Forest e o modelo de especialização deverão incorporar as variáveis externas quando forem compatíveis com o algoritmo.

4. Requisitos das bases de dados

As cinco bases serão comuns a toda a turma. Cada base deverá ser congelada antes do início da modelagem para que todos trabalhem com a mesma versão dos dados.

- Possuir uma variável-alvo numérica organizada no tempo.
- Apresentar frequência temporal regular ou ser adequadamente regularizada pelo grupo.
- Conter quantidade suficiente de observações e ciclos sazonais para análise.
- Possuir pelo menos duas variáveis externas potencialmente relacionadas ao alvo.
- Apresentar fonte, período de cobertura, unidade, frequência e significado das variáveis.
- Permitir a definição clara do horizonte de previsão e da data de origem das previsões.

4.1 Disponibilidade das variáveis externas

Para cada variável externa, o grupo deverá explicar se ela estaria disponível no momento real da previsão. Valores futuros observados não poderão ser utilizados como entrada, salvo quando forem efetivamente conhecidos com antecedência. Quando a variável não for conhecida no futuro, o grupo deverá utilizar valores defasados, uma previsão disponível na data de origem ou justificar sua exclusão.

Exemplo de variável	Disponibilidade para uma previsão futura
Dia da semana e feriados	Conhecidos antecipadamente
Promoção ou preço previamente planejado	Conhecidos antecipadamente
Temperatura realmente observada no futuro	Indisponível; causaria vazamento
Previsão meteorológica disponível na origem	Pode ser utilizada e deve ser identificada como previsão
Vendas futuras	Indisponíveis; não podem ser utilizadas como feature

5. Etapas obrigatórias

5.1 Documentação e exploração das cinco bases

- Apresentar fonte, descrição, período, frequência e unidade da variável-alvo.
- Construir um dicionário das variáveis externas.
- Verificar valores ausentes, duplicidades, irregularidades temporais e valores atípicos.
- Apresentar gráficos da série-alvo e das principais variáveis externas.
- Descrever as decisões de limpeza e transformação.

5.2 Decomposição e características temporais

- Realizar a decomposição STL da variável-alvo de cada base.
- Apresentar e interpretar visualmente o componente de tendência, indicando períodos de crescimento, queda, estabilidade e mudanças de direção.
- Apresentar e interpretar o componente sazonal e o componente residual.
- Calcular e interpretar a força da sazonalidade conforme o método apresentado em sala.

5.3 Feature Engineering

Os modelos baseados em tabela deverão utilizar um conjunto de features construído de maneira coerente com o horizonte de previsão. As mesmas features deverão ser utilizadas no Random Forest e no modelo de especialização sempre que houver compatibilidade, evitando que a comparação seja determinada por conjuntos de dados diferentes.

- Lags da variável-alvo e, quando pertinente, das variáveis externas.
- Estatísticas de janelas móveis, como média e desvio padrão.
- Features de calendário e encoding cíclico.
- Novas features que o grupo julgar necessárias e importantes.
- Variáveis externas disponíveis na data da previsão.
- Tratamento documentado dos valores ausentes produzidos pelos lags e janelas.

5.4 Validação walk-forward

A validação walk-forward simula o funcionamento real de um modelo de previsão ao longo do tempo. O processo começa com uma janela inicial de treinamento, utilizando somente as observações disponíveis até aquele momento. O modelo produz uma previsão para o horizonte definido; em seguida, o tempo avança, novas observações reais são incorporadas ao histórico e uma nova previsão é realizada. Esse procedimento é repetido até o fim do período de teste, gerando uma sequência de previsões fora da amostra. Todos os modelos deverão utilizar as mesmas datas de origem, o mesmo horizonte e o mesmo conjunto de teste. **Os grupos serão responsáveis por pesquisar e implementar esse método, mantendo fixos, durante o teste final, os hiperparâmetros previamente selecionados.**

5.5 Otimização dos hiperparâmetros

Cada grupo deverá pesquisar como realizar a otimização dos quatro modelos utilizados em cada base. A seleção dos hiperparâmetros deverá ocorrer antes da avaliação final, sem utilizar o conjunto de teste para tomar decisões. O relatório deverá informar o espaço de busca, o procedimento adotado, os valores selecionados e a justificativa das escolhas.

Modelo	Elementos mínimos a investigar
SARIMAX	Ordens p , d , q ; ordens sazonais P , D , Q ; período m ; AIC/BIC; variáveis externas
Holt-Winters	Tendência; sazonalidade; tendência amortecida; período sazonal; parâmetros de suavização
Random Forest	$n_estimators$; max_depth ; $min_samples_split$; $min_samples_leaf$; $max_features$
Modelo escolhido	Principais hiperparâmetros, efeitos, intervalos testados, método de busca e configuração final

5.6 Treinamento e previsão

- Executar os quatro modelos em cada uma das cinco bases.
- Utilizar as mesmas origens de previsão e o mesmo horizonte em todos os modelos.
- Impedir que observações futuras sejam utilizadas durante treinamento, criação de features ou otimização.
- Registrar parâmetros, tempo de execução, previsões e resíduos de cada combinação.

6. Avaliação comparativa por MAE

O Mean Absolute Error (MAE) será a métrica principal de comparação. O MAE deverá ser calculado sobre as previsões fora da amostra produzidas pelo walk-forward. Como as bases podem apresentar escalas diferentes, os valores de MAE não deverão ser somados nem calculados em média diretamente entre bases.

- Apresentar o MAE dos quatro modelos em cada base.
- Classificar os modelos do menor para o maior MAE dentro de cada base.
- Identificar o melhor modelo em cada base.
- Calcular a quantidade de vitórias e a posição média de cada modelo.
- Discutir em quais características das bases cada modelo apresentou melhor ou pior desempenho.

7. Análise dos resíduos

A análise deverá utilizar os erros fora da amostra, definidos pela diferença entre os valores reais e as previsões. Para cada combinação entre base e modelo, deverão ser apresentados métodos estatísticos e gráficos.

- Gráfico dos resíduos ao longo do tempo.
- Gráfico da função de autocorrelação (ACF) dos resíduos.
- Teste de Ljung-Box e interpretação do p-valor.
- Discussão sobre viés, padrões remanescentes, variabilidade e autocorrelação.

A tabela consolidada com os resultados do Ljung-Box deverá aparecer no corpo principal do relatório.

Gráficos complementares poderão ser organizados no apêndice, desde que os resultados mais relevantes sejam discutidos no texto principal.

8. Importância das features e interpretação

A importância das features deverá ser analisada no Random Forest e no modelo de especialização. Quando o modelo não possuir uma medida nativa, deverá ser empregado um método compatível, como Permutation Importance. As variáveis externas deverão ser destacadas e sua disponibilidade temporal deverá ser retomada na interpretação.

Modelo	Método de interpretação indicado
SARIMAX	Coeficientes das variáveis externas, sinal, magnitude e significância
Holt-Winters	Não possui feature importance; interpretar nível, tendência e sazonalidade
Random Forest	Importância nativa e/ou Permutation Importance
XGBoost	Gain, Permutation Importance ou SHAP
SVR	Permutation Importance ou método equivalente justificado
Elastic Net	Coeficientes após padronização
MLP Regressor	Permutation Importance ou método equivalente justificado
PLS Regression	Coeficientes, Permutation Importance ou VIP Scores

9. Estudo do modelo de especialização

Além da implementação, cada grupo deverá produzir uma explicação técnica e didática do modelo de especialização. A seção deverá demonstrar domínio conceitual e não se limitar à descrição do código utilizado.

- Funcionamento geral e intuição do algoritmo.
- Principais hipóteses, vantagens, limitações e requisitos de preparação dos dados.
- Papel e efeito dos principais hiperparâmetros.
- Método adotado para otimização.
- Método de importância das features e interpretação dos resultados.
- Desempenho do modelo nas cinco bases e possíveis explicações para as diferenças.

10. Relatório técnico

O grupo deverá produzir um relatório HTML paginado e uma versão final em PDF, ambos com o mesmo conteúdo. O documento deverá apresentar uma narrativa comparativa, explicar as decisões metodológicas e interpretar os resultados, evitando a simples reprodução de códigos e saídas.

10.1 Estrutura mínima do relatório

1. Resumo executivo.
2. Identificação dos integrantes e divisão de responsabilidades.
3. Documentação das cinco bases e das variáveis externas.
4. Limpeza, preparação e Feature Engineering.
5. STL, tendência e força da sazonalidade.
6. Protocolo walk-forward.
7. Modelos, hiperparâmetros e otimização.
8. Resultados comparativos por MAE.
9. Análise dos resíduos e teste de Ljung-Box.
10. Importância das features.
11. Explicação aprofundada do modelo escolhido.
12. Conclusões, limitações e recomendações.
13. Referências.
14. Apêndices técnicos e registro de demandas. (Apenas na Entrega para o professor)

11. Apresentação oral

Cada grupo realizará uma apresentação oral utilizando o relatório HTML paginado como material visual principal. O grupo deverá navegar pelas páginas ou seções do relatório, destacando o problema, as características das bases, o funcionamento do modelo de especialização, os resultados comparativos, os resíduos e a importância das features. Não será necessário produzir uma apresentação de slides separada.

- Todos os integrantes deverão participar da apresentação.
- A exposição deverá priorizar interpretação e comparação, e não leitura integral do relatório.
- O grupo deverá justificar escolhas metodológicas e responder a perguntas sobre qualquer uma das cinco bases.

12. Gestão do grupo por demandas

O grupo deverá manter um registro diário das demandas executadas por cada integrante. Cada linha deverá representar uma demanda realizada em um determinado dia, permitindo acompanhar responsabilidades, distribuição do trabalho, esforço e complexidade. O registro deverá ser incluído no relatório e considerado na avaliação da participação individual.

Data	Integrante	Demanda realizada	Entrega ou evidência	Carga de trabalho	Complexidade	Status
dd/mm	Nome	Descrição objetiva da tarefa	Arquivo, seção, código ou resultado	Baixa / Média / Alta	Baixa / Média / Alta	A fazer / Em andamento / Concluída

12.1 Classificação da carga de trabalho

- Baixa: tarefa curta, de escopo reduzido e pouco esforço operacional.
- Média: tarefa com esforço moderado, múltiplas etapas ou necessidade de revisão.
- Alta: tarefa extensa, com esforço significativo, integração de partes ou grande volume de análise.

12.2 Classificação da complexidade

- Baixa: procedimento conhecido, repetitivo ou diretamente orientado.
- Média: exige análise, adaptação de código ou tomada de decisão metodológica.
- Alta: exige pesquisa, solução de problema novo, integração de modelos ou decisão técnica relevante.

Uma tarefa pode possuir carga alta e complexidade baixa, ou carga baixa e complexidade alta. Os dois critérios deverão ser avaliados separadamente. Registros genéricos, como "ajudei no trabalho", não serão aceitos como descrição de demanda.

13. Entrega pela Plataforma Odete

A entrega deverá ser realizada pela Plataforma Odete, dentro do prazo nela informado. O grupo deverá enviar um único arquivo compactado com os itens obrigatórios abaixo.

- Relatório final em PDF.
- Relatório HTML paginado e autocontido.
- Arquivo-fonte utilizado para gerar o relatório, como .ipynb.
- Códigos organizados utilizados na análise.
- Cinco bases utilizadas ou indicação clara das fontes.
- Arquivo consolidado de resultados por MAE.
- Registro diário de demandas de todos os integrantes.

Sugestão de nome do arquivo: Grupo_XX_Trabalho_Series_Temporais.zip

14. Critérios de avaliação

Critério	Peso
Documentação, qualidade e compreensão das cinco bases	5%
STL, interpretação da tendência e força da sazonalidade	5%
Feature Engineering, disponibilidade das variáveis e prevenção de vazamento	10%
Implementação dos modelos e validação walk-forward	15%
Pesquisa e otimização dos hiperparâmetros	10%
Comparação dos resultados por MAE	10%
Análise dos resíduos, ACF e Ljung-Box	5%
Modelo escolhido e importância das features	20%
Qualidade técnica do HTML e do PDF	10%
Apresentação oral utilizando o relatório paginado	5%
Gestão diária das demandas e participação dos integrantes	5%

A nota individual poderá ser ajustada quando o registro de demandas, os arquivos entregues e a participação na apresentação indicarem diferenças relevantes de contribuição entre os integrantes.

15. Regras gerais

- Todos os resultados deverão ser reproduzíveis a partir dos arquivos entregues.
- As fontes das bases, bibliotecas, referências técnicas e materiais consultados deverão ser citadas.
- Os grupos deverão utilizar exatamente as versões congeladas das cinco bases.
- Qualquer alteração de modelo, base, horizonte ou protocolo deverá ser previamente aprovada.
- O uso de ferramentas de Inteligência Artificial deverá ser acompanhado de revisão crítica, compreensão do código e responsabilidade sobre os resultados apresentados.