

Modelagem comparativa de séries temporais com variáveis externas

Fernando Paiva · Giovanna Pelati · João Vargas · Matheus Cury · Sophia Gasparetto

Gerado a partir dos artefatos persistidos em 2026-10-05T11:03:05-03:00

Sumário

- 01 Resumo executivo
- 02 Identificação dos integrantes e divisão de responsabilidades
- 03 Documentação das cinco bases e das variáveis externas
- 04 Limpeza, preparação e Feature Engineering
- 05 STL, tendência e força da sazonalidade
- 06 Protocolo walk-forward
- 07 Modelos, hiperparâmetros e otimização
- 08 Resultados comparativos por MAE
- 09 Análise dos resíduos e teste de Ljung-Box
- 10 Importância das features
- 11 Explicação aprofundada do modelo escolhido
- 12 Conclusões, limitações e recomendações
- 13 Referências
- 14 Apêndices técnicos e registro de demandas

01 Resumo executivo

O trabalho compara SARIMAX, Holt-Winters, Random Forest e PLS Regression, o modelo de especialização do Grupo 5, em cinco séries temporais com variáveis externas. Todos os modelos usam as mesmas origens, o mesmo horizonte e o mesmo conjunto de teste, com validação walk-forward e hiperparâmetros escolhidos antes do teste. A métrica é o MAE, comparado apenas dentro de cada base.

Não há modelo universal: **SARIMAX** venceu Microsoft; **Holt-Winters** venceu Brasil, Delhi e Pilgrim's Pride; **Random Forest** venceu Sales. No placar, Holt-Winters lidera com 3 vitórias e posição média 1,8. O PLS não venceu nenhuma base, teve posição média 2,8 e foi o 2º colocado nas bases Brasil e Delhi. Ele foi mais útil onde o alvo é ruidoso e as features são muito correlacionadas, e menos útil onde o último valor observado já é quase toda a informação disponível (seção 11).

Três limitações condicionam a leitura: em Sales, cinco meses sem nenhuma transação na fonte viraram lucro zero na preparação (seção 4); nos modelos com horizonte maior que 1 o Ljung-Box agregado rejeita ruído branco por construção, e por isso o diagnóstico é feito também por passo (seção 9); e a winsorização das externas do PLS foi decidida depois de um erro observado no teste de Delhi (seção 11). Kalman e Fourier+ACF são bônus e não entram no placar.

Vencedor de cada base (MAE de teste)

base	vencedor	MAE	MAE ingênuo	ganho sobre o ingênuo (%)
Brasil	Holt-Winters	2,645	3,818	30,7
Delhi	Holt-Winters	1,885	1,944	3,1
Microsoft	SARIMAX	1,503	2,542	40,9
Pilgrim's Pride	Holt-Winters	0,616	0,616	3,47e-08
Sales	Random Forest	5.479,244	7.325,654	25,2

Placar das 20 combinações oficiais

modelo	vitórias	posição média	melhor posição	pior posição
Holt-Winters	3	1,8	1	4
SARIMAX	1	2,6	1	4
Random Forest	1	2,8	1	4
PLS	0	2,8	2	4

02 Identificação dos integrantes e divisão de responsabilidades

O grupo é formado por Fernando Paiva, Giovanna Pelati, João Vargas, Matheus Cury e Sophia Gasparetto. A tabela resume as frentes de cada integrante; o registro diário completo, com carga, complexidade, status e evidência de cada demanda, está no apêndice (seção 14). As evidências são commits do repositório e arquivos entregues; quando não há arquivo, a linha é marcada como relato do integrante.

Divisão de responsabilidades

Integrante	demandas	demandas mais recentes	período
Fernando Paiva	3	Organização geral do projeto; Definição das especificações e das bases; Adição de elementos na pipeline padrão	10/09/2026 a 17/09/2026
Giovanna Pelati	6	Implementação do PLS (remoção de redundâncias; winsorização das externas; grade até o posto de X; VIP); Revisão final: reexecução isolada dos notebooks e verificação de reprodutibilidade das 31 configurações; Correção da divergência código x resultados (SARIMAX sem winsorização; Kalman refeito); limpeza do repositório; relatório final	10/09/2026 a 05/10/2026
João Vargas	4	Estudo e documentação do projeto; Base do relatório e entendimento da pipeline; Primeira versão do relatório (Markdown; HTML; PDF) e tabelas de MAE e Ljung-Box	10/09/2026 a 27/09/2026
Matheus Cury	11	Primeira rodada de treino dos modelos; Rodada completa do pipeline (5 bases x 4 modelos) com caches do SARIMAX; Bônus Kalman e Fourier+ACF; checkpoints; gerador do relatório; consolidação dos artefatos	10/09/2026 a 01/10/2026
Sophia Gasparetto	5	Notebook reprodutível de preparação das cinco bases; Correção da preparação das bases Brasil e Sales; Exploração aprofundada das bases (item 5.1): estatísticas; checagens de consistência; painéis	10/09/2026 a 29/09/2026

03 Documentação das cinco bases e das variáveis externas

As cinco bases são as versões congeladas em `bases/raw/`, transformadas pelo `prepare_bases.ipynb` em séries prontas para modelagem (`bases/*_prepared.csv`). A reexecução da preparação reproduz os cinco arquivos byte a byte, e o SHA-256 de cada um fica registrado abaixo.

Visão geral das bases

base	descrição	alvo	unidade	frequência	período	observações	horizonte h
Delhi	Temperatura média diária em Delhi (Índia), com umidade, vento e pressão do mesmo dia.	meantemp	°C	diária	2013-01-01 a 2017-04-24	1.575	7
Pilgrim's Pride	Preço de fechamento diário da ação da Pilgrim's Pride, com abertura, máxima, mínima e volume da sessão.	Close	USD por ação (NASDAQ: PPC)	pregões observados	1987-12-30 a 2026-09-16	9.751	5
Microsoft	Preço de abertura da sessão da Microsoft, com fechamento e volume da sessão anterior.	target_open	USD por ação (NASDAQ: MSFT)	pregões observados	2015-04-02 a 2021-03-31	1.510	1
Sales	Lucro diário de vendas de bicicletas e acessórios na Europa, com quantidade vendida e número de transações.	Profit	moeda não informada na fonte	diária	2011-01-01 a 2016-07-31	2.039	7
Brasil	Vitórias anuais da Seleção Brasileira, com partidas disputadas e amistosos no ano.	victories	vitórias por ano	anual	1914-01-01 a 2022-01-01	109	1

Fontes e rastreabilidade

base	fonte	arquivo(s) bruto(s)	arquivo preparado	SHA-256 do preparado
Delhi	https://www.kaggle.com/datasets/sumanthvrao/daily-climate-time-series-data	DailyDelhiClimateTrain.csv; DailyDelhiClimateTest.csv	daily_delhi_climate_prepared.csv	41f38ab6840f7db11709d070a01f8ea593568225cdb1ce6ac0d34f1a8239549a
Pilgrim's Pride	https://www.kaggle.com/datasets/mandalorianforza/pilgrims-pride-ppc-daily-stock-price-history	Pilgrim_s_Pride_Corporation_1987-12-30_2026-09-16.csv	pilgrims_pride_prepared.csv	b517e7246915d1548d026155efab93e94f44b71cd4446e8068280b3f893784ab
Microsoft	https://www.kaggle.com/datasets/vijayvvenkitesh/microsoft-stock-time-series-analysis	Microsoft_Stock.csv	microsoft_stock_prepared.csv	efeee129496b40c1450e532ae7a1017e64353d53c4f9dc95e2673a375362d587
Sales	https://www.kaggle.com/datasets/sadiqshah/bike-sales-in-europe	Sales.csv	sales_prepared.csv	507b42cb5c1d4564971f0d09f601f0611ee59fc31f082ee051fc36d1894269dc
Brasil	https://www.kaggle.com/datasets/azminetoushikwasi/brazil-all-international-matches-19142023	brazil.csv	brazil_prepared.csv	e7d2d3293b13b929f1af8acda01462db4e56f06a7a268cf5745c1ac710b5bd45

Horizontes: 7 dias em Delhi e Sales (uma semana à frente), 5 pregões em Pilgrim's (uma semana útil), 1 pregão em Microsoft (a abertura de amanhã) e 1 ano no Brasil. A data de origem é a última observação disponível em cada passo do walk-forward. As unidades de Delhi não constam na fonte e foram inferidas pela faixa de valores; as ações são cotadas em dólar na NASDAQ; a moeda de Sales não é informada.


Dicionário das variáveis

Papel, unidade e disponibilidade de cada variável (prepare_bases.ipynb)


Base	Variável	Papel	Descrição	Unidade	Disponibilidade
Delhi Climate	meantemp	Alvo	Temperatura média diária	°C	Não disponível
Delhi Climate	humidity	Externa	Umidade média diária	% (inferida pela faixa; a fonte não informa)	Somente defasada
Delhi Climate	wind_speed	Externa	Velocidade média do vento	km/h (inferida pela faixa; a fonte não informa)	Somente defasada
Delhi Climate	meanpressure	Externa	Pressão atmosférica média	hPa (inferida pela faixa; a fonte não informa)	Somente defasada
Pilgrim's Pride	Open	Externa	Preço de abertura	USD	Somente após a abertura
Pilgrim's Pride	High	Externa	Maior preço da sessão	USD	Somente defasada
Pilgrim's Pride	Low	Externa	Menor preço da sessão	USD	Somente defasada
Pilgrim's Pride	Close	Alvo	Preço de fechamento	USD	Não disponível
Pilgrim's Pride	Volume	Externa	Volume negociado	Quantidade	Somente defasada
Pilgrim's Pride	Dividends	Externa	Dividendo registrado	USD	Depende do anúncio
Pilgrim's Pride	Stock Splits	Externa	Fator de desdobramento	Razão	Depende do anúncio
Seleção Brasileira	victories	Alvo	Vitórias no ano	Contagem	Não disponível
Seleção Brasileira	matches_played	Externa	Partidas disputadas no ano	Contagem	Somente defasada
Seleção Brasileira	friendly_matches	Externa	Amistosos disputados no ano	Contagem	Somente defasada
Bike Sales	Profit	Alvo	Lucro total diário	Moeda não informada	Não disponível
Bike Sales	order_quantity	Externa	Itens vendidos no dia	Unidades	Somente defasada
Bike Sales	transaction_count	Externa	Transações no dia	Contagem	Somente defasada
Microsoft Stock	target_open	Alvo	Preço de abertura da sessão	USD	Não disponível
Microsoft Stock	close_lag_1	Externa defasada	Fechamento da sessão anterior	USD	Disponível

Base	Variável	Papel	Descrição	Unidade	Disponibilidade
Microsoft Stock	volume_lag_1	Externa defasada	Volume da sessão anterior	Quantidade	Disponível

Série-alvo e variáveis externas




Delhi: alvo e variáveis externas na série completa




Pilgrim's Pride: alvo e variáveis externas na série completa

Alvo e externas · Microsoft




Microsoft: alvo e variáveis externas na série completa

Alvo e externas - Sales



Sales: alvo e variáveis externas na série completa

Alvo e externas - Brasil




Brasil: alvo e variáveis externas na série completa

Painéis exploratórios


Cada painel reúne evolução com média móvel, distribuição do alvo, correlações, perfil por período, relação com uma externa relevante e variação entre observações consecutivas.

Diagnóstico exploratório — Delhi Climate




Delhi: diagnóstico exploratório

Diagnóstico exploratório — Pilgrim's Pride








Pilgrim's Pride: diagnóstico exploratório

Diagnóstico exploratório — Microsoft Stock









Microsoft: diagnóstico exploratório

Diagnóstico exploratório — Bike Sales



Sales: diagnóstico exploratório

Diagnóstico exploratório — Seleção Brasileira



Brasil: diagnóstico exploratório

04 Limpeza, preparação e Feature Engineering

Qualidade dos dados e decisões de limpeza

Auditoria das bases preparadas

base	ausentes	datas duplicadas	intervalos distintos entre datas	outliers IQR do alvo
Delhi	0	0	1	0
Pilgrim's Pride	0	0	6	161
Microsoft	0	0	4	0
Sales	0	0	1	9
Brasil	0	0	2	1

Outliers do alvo são contados, não removidos: em preço e clima o ponto extremo costuma ser o evento real que mais importa prever. Em séries com tendência, como as ações, o critério IQR global marca como atípicos níveis apenas novos, por isso serve só como triagem. Os intervalos irregulares das ações são fins de semana e feriados: as sessões são mantidas como observadas, sem inventar preços.

Decisões de limpeza e transformação (prepare_bases.ipynb)

Base	Situação	Decisão	Justificativa
Delhi Climate	Sobreposição em 01/01/2017	Manter o valor do teste	Regra explícita de precedência
Delhi Climate	Lacunas diárias	Preenchimento para frente	Usa somente informação passada
Pilgrim's Pride	Dias sem pregão	Não preencher	Não representam negociações ausentes
Seleção Brasileira	Registro de 05/09/2021 sem resultado	Excluir	Não possui desfecho utilizável
Seleção Brasileira	Anos sem partidas	Preencher com zero	Mantém a frequência anual
Bike Sales	Várias transações na mesma data	Agregar por dia	As linhas representam transações
Bike Sales	Dias sem registros	Preencher com zero	Mantém a frequência diária; ago-dez/2014 não tem nenhum registro na fonte (lacuna de dados, documentada como limitação)
Bike Sales	1.000 linhas idênticas na fonte	Manter e somar	Sem identificador de transação, não há como provar duplicação; documentado como limitação
Microsoft Stock	Primeira linha sem valores anteriores	Excluir	Não é possível calcular os lags

Base	Situação	Decisão	Justificativa
Microsoft Stock	Dias sem pregão	Não preencher	Não criar preços artificiais

Checagens de consistência específicas de cada base

Base	Verificação	Ocorrências	Interpretação
Delhi Climate	Umidade fora de 0% a 100%	0	Revisar se maior que zero
Delhi Climate	Velocidade do vento negativa	0	Deve ser zero
Delhi Climate	Pressão fora de 870 a 1.100 hPa	8	Possíveis erros de medição/registro
Pilgrim's Pride	High menor que Open/Close	0	Deve ser zero
Pilgrim's Pride	Low maior que Open/Close	0	Deve ser zero
Pilgrim's Pride	Sessões com volume zero	10	Investigar, mas não excluir automaticamente
Seleção Brasileira	Vitórias maiores que partidas	0	Deve ser zero
Seleção Brasileira	Amistosos maiores que partidas	0	Deve ser zero
Seleção Brasileira	Anos sem partidas registradas	12	Cobertura histórica incompleta
Bike Sales	Dias com lucro zero	155	Compatível com dias sem vendas
Bike Sales	Lucro positivo sem transações	0	Deve ser zero
Microsoft Stock	Preços de abertura não positivos	0	Deve ser zero
Microsoft Stock	Volumes anteriores negativos	0	Deve ser zero

Alertas que afetam a modelagem. Em Delhi, 8 registros de pressão estão fora da faixa física de 870 a 1.100 hPa; eles foram mantidos na base e tratados apenas no PLS e no Kalman, por winsorização das externas aprendida no treino de cada origem. O SARIMAX usa as externas sem tratamento. Em Sales, a fonte não tem nenhuma transação entre 01/08/2014 e 31/12/2014 (153 dias). Como a preparação preenche dias sem registro com zero, esse intervalo virou lucro zero: 119 dias no fim da validação e 34 no início do teste. O padrão (dados só de janeiro a julho) se repete em 2016, o que indica ausência de dados e não ausência de vendas. A fonte também contém 1.000 linhas idênticas em todas as colunas; sem identificador de transação, não há como provar que são duplicações, e a preparação as soma como transações. As duas situações foram mantidas para não alterar a base congelada e estão discutidas nas limitações.

Feature Engineering

Random Forest e PLS recebem a mesma tabela de features. A regra é única: uma linha com data t só usa informação de até $t - h$. Lags do alvo em $\{h, h+1, h+2, h+3, m, m+h\}$, filtrados para $\text{lag} \geq h$; média e desvio móveis em janelas de 4, 8 e 12 calculados depois de $\text{shift}(h)$; delta_nivel = média de 4 – média de 12; calendário (mês, dia da semana, semana) com codificação seno/cosseno. Externas conhecidas na origem entram com o valor da própria data; externas observadas só depois entram defasadas em h . As primeiras linhas, sem histórico suficiente para os lags, são descartadas (*dropna*), e colunas constantes, como o calendário da série anual do Brasil, são removidas.

Tamanho da tabela de features

base	features (RF e PLS)	features no PLS	removidas no PLS (combinação linear exata)
Delhi	25	23	media_4, delta_nivel
Pilgrim's Pride	22	20	media_4, delta_nivel
Microsoft	24	22	media_4, delta_nivel
Sales	23	21	media_4, delta_nivel
Brasil	20	17	media_4, delta_nivel, semana_cos

Disponibilidade e seleção das variáveis externas

Cada externa foi avaliada na versão que realmente entra no modelo (já defasada): correlação de Pearson com o alvo e VIF entre as externas, com poda iterativa da de maior VIF até todas ficarem abaixo de 10.

Disponibilidade, correlação e colinearidade das externas

base	exogena	papel	disponivel_na_origem	como_entra	r	p_valor	significativa	VIF	decisao
Brasil	friendly_matches_lag_1	defasada	nao	defasada em h	0,393	0,0004	sim	2,7	mantida
Brasil	matches_played_lag_1	defasada	nao	defasada em h	0,375	0,0008	sim	2,7	mantida
Delhi	humidity_lag_7	defasada	nao	defasada em h	-0,533	0,0000	sim	1,3	mantida
Delhi	meanpressure_lag_7	defasada	nao	defasada em h	-0,844	0,0000	sim	1,2	mantida
Delhi	wind_speed_lag_7	defasada	nao	defasada em h	0,333	0,0000	sim	1,2	mantida
Microsoft	close_lag_1	conhecida	sim	valor da propria data	1,000	0,0000	sim	1,0	mantida
Microsoft	volume_lag_1	conhecida	sim	valor da propria data	-0,111	0,0003	sim	1,0	mantida
Pilgrim's Pride	Low_lag_5	defasada	nao	defasada em h	0,995	0,0000	sim	1,1	mantida

base	exogena	papel	disponivel_na_origem	como_entra	r	p_valor	significativa	VIF	decisao
Pilgrim's Pride	Volume_lag_5	defasada	nao	defasada em h	0,294	0,0000	sim	1,1	mantida
Pilgrim's Pride	High_lag_5	defasada	nao	defasada em h	0,995	0,0000	sim	1.134,6	removida
Pilgrim's Pride	Open_lag_5	defasada	nao	defasada em h	0,995	0,0000	sim	2.038,8	removida
Sales	transaction_count_lag_7	defasada	nao	defasada em h	0,849	0,0000	sim	1,0	mantida
Sales	order_quantity_lag_7	defasada	nao	defasada em h	0,837	0,0000	sim	108,9	removida

05 STL, tendência e força da sazonalidade

A STL é calculada sobre treino + validação, sem tocar no teste. A força da sazonalidade é $1 - \text{Var}(\text{resíduo}) / \text{Var}(\text{sazonal} + \text{resíduo})$: perto de 1 o ciclo domina, perto de 0 é ruído. O período m usado pelos modelos é o de maior força até 30, limite computacional do SARIMAX; ciclos mais longos ficam a cargo das features de calendário. Com força abaixo de 0,05, a série é tratada como não sazonal ($m = 1$) e a STL do gráfico usa o período de maior força só para visualização.

Período sazonal e decomposição

base	m usado	força sazonal em m	m de maior força	% variância sazonal (STL)	% variância residual (STL)
Delhi	30	0,271	365	2,0	5,1
Pilgrim's Pride	1	-0,006	52	0,5	1,4
Microsoft	30	0,201	252	0,2	0,4
Sales	12	0,156	12	4,2	12,9
Brasil	4	0,345	4	21,5	27,8

A tendência de Delhi tem 8 fases (3 de alta, 5 de queda, 0 de estabilidade); a maior alta vai de 2015-01-13 a 2015-05-29 (20,91 no nível); a maior queda vai de 2014-06-23 a 2015-01-08 (-21,32). Houve 7 mudanças de direção classificadas. A força sazonal em $m = 30$ é 0,271; o período de maior força é $m = 365$. O resíduo da STL responde por 5,1% da variância da série. Como $m = 30$, o ciclo anual não cabe no componente sazonal e aparece na tendência: as fases de alta e queda de Delhi são, na prática, as estações do ano.

A tendência de Pilgrim's Pride tem 7 fases (4 de alta, 2 de queda, 1 de estabilidade); a maior alta vai de 2003-02-18 a 2005-05-11 (17,81 no nível); a maior queda vai de 2007-06-22 a 2009-04-02 (-21,67). Houve 6 mudanças de direção classificadas. Não há sazonalidade útil ($m = 1$; força máxima -0,006); o período de maior força é $m = 52$. O resíduo da STL responde por 1,4% da variância da série.

A tendência de Microsoft tem 5 fases (3 de alta, 2 de queda, 0 de estabilidade); a maior alta vai de 2016-06-06 a 2018-09-21 (59,33 no nível); a maior queda vai de 2018-10-02 a 2019-01-02 (-4,63). Houve 4 mudanças de direção classificadas. A força sazonal em $m = 30$ é 0,201; o período de maior força é $m = 252$. O resíduo da STL responde por 0,4% da variância da série.

A tendência de Sales tem 6 fases (2 de alta, 1 de queda, 3 de estabilidade); a maior alta vai de 2013-06-03 a 2013-09-23 (21.001,02 no nível); a maior queda vai de 2014-05-30 a 2014-08-31 (-34.823,59). Houve 5 mudanças de direção classificadas. A força sazonal em $m = 12$ é 0,156. O resíduo da STL responde por 12,9% da variância da série. A maior queda coincide com a lacuna de dados de 2014 (seção 4), e não com uma queda real de vendas.

A tendência de Brasil tem 11 fases (7 de alta, 4 de queda, 0 de estabilidade); a maior alta vai de 1953-01-01 a 1962-01-01 (6,41 no nível); a maior queda vai de 1963-01-01 a 1967-01-01 (-3,24). Houve 10 mudanças de direção classificadas. A força sazonal em $m = 4$ é 0,345. O resíduo da STL responde por 27,8% da variância da série.


Leitura por base: Delhi tem ciclo anual muito forte (força próxima de 1 em $m = 365$) que o SARIMAX não comporta, então $m = 30$ captura só parte dele e o restante fica no calendário; Pilgrim's e Microsoft são dominadas pela tendência, com sazonalidade fraca; Sales combina crescimento com forte ruído diário; no Brasil, o ciclo de 4 anos da Copa do Mundo é o mais forte.

Fases da tendência (inclinação normalizada; fases curtas absorvidas)

base	fase	inicio	fim	pontos	variacao	variacao_pct
Delhi	alta	2013-01-24	2013-05-26	123	19,81	143,4
Delhi	queda	2013-06-06	2013-08-06	62	-3,76	-11,2
Delhi	queda	2013-09-06	2014-01-08	125	-16,74	-55,6
Delhi	alta	2014-01-19	2014-06-12	145	20,18	145,8
Delhi	queda	2014-06-23	2015-01-08	200	-21,32	-63,0
Delhi	alta	2015-01-13	2015-05-29	137	20,91	165,8
Delhi	queda	2015-06-09	2015-07-29	51	-3,33	-10,0
Delhi	queda	2015-09-07	2015-12-18	103	-16,05	-51,6
Pilgrim's Pride	estavel	1990-05-23	1995-05-11	1.257	0,05	1,7
Pilgrim's Pride	alta	1996-06-25	1998-12-07	620	6,06	194,8
Pilgrim's Pride	queda	1999-01-25	2000-04-24	316	-4,14	-47,0
Pilgrim's Pride	alta	2000-08-09	2001-11-23	323	4,09	92,5
Pilgrim's Pride	alta	2003-02-18	2005-05-11	563	17,81	362,9
Pilgrim's Pride	queda	2007-06-22	2009-04-02	449	-21,67	-94,2
Pilgrim's Pride	alta	2012-03-29	2014-07-15	576	13,38	306,6
Microsoft	queda	2015-06-12	2015-08-28	55	-1,65	-3,6
Microsoft	alta	2015-09-09	2015-12-10	66	10,45	23,6
Microsoft	alta	2016-06-06	2018-09-21	580	59,33	116,0
Microsoft	queda	2018-10-02	2019-01-02	63	-4,63	-4,2
Microsoft	alta	2019-01-09	2019-05-15	88	20,07	19,0
Sales	estavel	2011-01-01	2011-03-14	73	1.337,93	21,8


base	fase	inicio	fim	pontos	variacao	variacao_pct
Sales	estavel	2013-01-29	2013-06-02	125	1.730,59	37,2
Sales	alta	2013-06-03	2013-09-23	113	21.001,02	329,6
Sales	alta	2014-03-20	2014-05-27	69	8.752,21	33,2
Sales	queda	2014-05-30	2014-08-31	94	-34.823,59	-99,9
Sales	estavel	2014-09-01	2014-11-27	88	-21,41	-99,9
Brasil	alta	1916-01-01	1921-01-01	6	0,84	82,9
Brasil	queda	1923-01-01	1927-01-01	5	-1,27	-76,7
Brasil	alta	1928-01-01	1930-01-01	3	0,54	110,7
Brasil	alta	1935-01-01	1939-01-01	5	1,22	158,9
Brasil	alta	1942-01-01	1950-01-01	9	1,73	80,7
Brasil	alta	1953-01-01	1962-01-01	10	6,41	171,4
Brasil	queda	1963-01-01	1967-01-01	5	-3,24	-34,2
Brasil	queda	1971-01-01	1974-01-01	4	-0,50	-7,5
Brasil	alta	1977-01-01	1980-01-01	4	1,42	22,7
Brasil	queda	1981-01-01	1984-01-01	4	-1,72	-22,5
Brasil	alta	1985-01-01	1988-01-01	4	2,40	39,6

STL - Delhi - período 30 (treino + validação)




Delhi: decomposição STL

STL · Pilgrim's Pride · período 52 (treino + validação)




Pilgrim's Pride: decomposição STL

STL · Microsoft · período 30 (treino + validação)




Microsoft: decomposição STL

STL - Sales - período 12 (treino + validação)



Sales: decomposição STL

STL - Brasil - período 4 (treino + validação)



Brasil: decomposição STL

06 Protocolo walk-forward

O corte é cronológico: os 30% finais da série são o teste e, dentro dos 70% anteriores, os 30% finais são a validação. Em cada origem, o modelo é ajustado só com o passado, prevê as h datas seguintes, e a origem avança h passos, incorporando os valores observados. Como o passo é igual a h , os blocos de previsão não se sobrepõem e cada data do teste é prevista uma única vez por modelo.

A validação usa no máximo 30 origens espaçadas pela janela, porque cada combinação de hiperparâmetros custa um walk-forward inteiro; o teste usa todas as origens. Os hiperparâmetros são congelados antes do teste, e os quatro modelos recebem exatamente as mesmas origens (conferido abaixo).

Cortes treino / validação / teste

base	obs	h	treino	validação	teste
Delhi	1.575	7	772	331	472
Pilgrim's Pride	9.751	5	4.778	2.048	2.925
Microsoft	1.510	1	740	317	453
Sales	2.039	7	999	428	612
Brasil	109	1	53	23	33

Número de origens de teste por modelo (iguais em cada base)

base	Holt-Winters	PLS	Random Forest	SARIMAX
Brasil	33	33	33	33
Delhi	67	67	67	67
Microsoft	453	453	453	453
Pilgrim's Pride	585	585	585	585
Sales	87	87	87	87

Validação walk-forward sem acesso ao futuro



Esquema do walk-forward

07 Modelos, hiperparâmetros e otimização

Toda a seleção usa somente treino e validação. SARIMAX: d e D vêm dos testes ADF e KPSS (só se considera a série estacionária quando os dois concordam), m vem da STL, e a grade cobre p , q , P , Q de 0 a 2 e d , D até o sugerido. Como AIC/BIC medem ajuste dentro da amostra e o MAE mede erro fora dela, a decisão é em duas etapas: BIC na grade inteira e MAE de validação nas 10 melhores por BIC; vence a menor soma de BIC e MAE normalizados. Holt-Winters: grade de tendência (aditiva ou ausente), sazonalidade (aditiva, multiplicativa ou ausente) e amortecimento, decidida pelo MAE de validação; os parâmetros de suavização são estimados por máxima verossimilhança. Random Forest: busca aleatória de 16 das 48 combinações de $n_estimators$, max_depth , $max_features$, $min_samples_split$ e $min_samples_leaf$. PLS: grade exaustiva de $n_components$ de 1 até o posto de X (seção 11).

Espaço de busca

modelo	espaço de busca	procedimento	critério
SARIMAX	$p, q, P, Q \in \{0, 1, 2\}$; $d \leq d$ sugerido; $D \leq D$ sugerido; m da STL; externas após VIF	grade completa + top 10 por BIC	BIC + MAE de validação normalizados
Holt-Winters	tendência {add, nenhuma}; sazonal {add, mul, nenhuma}; amortecida {sim, não}	grade completa	MAE de validação
Random Forest	$n_estimators$ {300, 600}; max_depth {None, 6, 12}; $max_features$ {sqrt, 0,5}; $min_samples_split$ {2, 5}; $min_samples_leaf$ {1, 2}	16 sorteios (random_state = 42)	MAE de validação
PLS	$n_components$ de 1 até min(30, posto de X , menor treino - 1)	grade completa	MAE de validação

Estacionariedade e ordens de diferenciação

base	ADF p-valor (nível)	KPSS p-valor (nível)	estacionaria	d	D	m
Delhi	0,2829	0,1000	não	1	0	30
Pilgrim's Pride	0,7925	0,0100	não	1	0	1
Microsoft	0,9951	0,0100	não	1	0	30
Sales	0,4107	0,0100	não	1	0	12
Brasil	0,7112	0,0100	não	1	0	4

Configuração final de cada combinação (tempo = otimização + walk-forward de teste)

base	modelo	configuração escolhida	candidatos avaliados	MAE de validação	AIC	BIC	tempo (s)
Brasil	Holt-Winters	{'trend': None, 'seasonal': 'add', 'damped': False}	9	2,662	—	—	0,7

base	modelo	configuração escolhida	candidatos avaliados	MAE de validação	AIC	BIC	tempo (s)
Brasil	PLS	{'n_components': 1}	17	2,837	—	—	1,0
Brasil	Random Forest	{'n_estimators': 300, 'max_depth': 12, 'max_features': 'sqrt', 'min_samples_split': 2, 'min_samples_leaf': 1}	16	2,875	—	—	16,2
Brasil	SARIMAX	{'order': (0, 1, 2), 'seasonal_order': (0, 0, 2, 4)}	10	2,973	336,3	351,4	2,7
Delhi	Holt-Winters	{'trend': 'add', 'seasonal': None, 'damped': True}	9	2,010	—	—	9,7
Delhi	PLS	{'n_components': 20}	23	1,916	—	—	3,2
Delhi	Random Forest	{'n_estimators': 600, 'max_depth': None, 'max_features': 'sqrt', 'min_samples_split': 5, 'min_samples_leaf': 2}	16	1,668	—	—	146,9
Delhi	SARIMAX	{'order': (1, 1, 2), 'seasonal_order': (0, 0, 2, 30)}	10	1,888	3.929,7	3.974,2	4.848,6
Microsoft	Holt-Winters	{'trend': 'add', 'seasonal': 'mul', 'damped': False}	9	1,295	—	—	81,1
Microsoft	PLS	{'n_components': 13}	22	1,195	—	—	4,0
Microsoft	Random Forest	{'n_estimators': 300, 'max_depth': 12, 'max_features': 0.5, 'min_samples_split': 5, 'min_samples_leaf': 1}	16	1,226	—	—	425,4
Microsoft	SARIMAX	{'order': (0, 0, 0), 'seasonal_order': (2, 0, 0, 30)}	10	0,734	2.145,9	2.170,5	1.142,4
Pilgrim's Pride	Holt-Winters	{'trend': None, 'seasonal': None, 'damped': False}	3	0,308	—	—	6,1
Pilgrim's Pride	PLS	{'n_components': 19}	20	0,497	—	—	13,7
Pilgrim's Pride	Random Forest	{'n_estimators': 300, 'max_depth': None, 'max_features': 'sqrt', 'min_samples_split': 5, 'min_samples_leaf': 1}	16	0,497	—	—	2.414,5
Pilgrim's Pride	SARIMAX	{'order': (1, 1, 0), 'seasonal_order': (0, 0, 0, 0)}	10	0,306	722,2	749,5	262,6
Sales	Holt-Winters	{'trend': None, 'seasonal': None, 'damped': False}	9	4.081,372	—	—	3,6
Sales	PLS	{'n_components': 5}	21	4.791,286	—	—	2,8
Sales	Random Forest	{'n_estimators': 600, 'max_depth': 12, 'max_features': 'sqrt', 'min_samples_split': 5, 'min_samples_leaf': 1}	16	4.079,100	—	—	174,8
Sales	SARIMAX	{'order': (0, 1, 2), 'seasonal_order': (0, 0, 2, 12)}	10	4.100,256	27.723,4	27.754,8	162,9

No SARIMAX, o número de candidatos é o das 10 melhores por BIC, que passam pelo MAE de validação; a grade inteira está em resultados/busca.csv e resultados/cache_sarimax_*. Os parâmetros de suavização do Holt-Winters, estimados no fim do treino com a configuração congelada, mostram quão rápido cada componente reage ao dado novo (perto de 1 = reage quase só ao último valor).

Holt-Winters: forma escolhida e parâmetros de suavização

base	trend	seasonal	damped	m	alpha_nivel	beta_tendencia	gamma_sazonal	phi_amortecimento
Delhi	add	—	sim	30	0,765	0,000	—	0,987
Pilgrim's Pride	—	—	não	1	1,000	—	—	—
Microsoft	add	mul	não	30	1,000	0,000	8,91e-09	—
Sales	—	—	não	12	0,199	—	—	—
Brasil	—	add	não	4	0,204	—	0,000	—

08 Resultados comparativos por MAE

O MAE é calculado sobre todas as previsões fora da amostra do teste. Como as bases têm escalas diferentes, o MAE não é somado nem promediado entre bases: compara-se a posição dentro de cada base. A coluna de ganho compara cada modelo com a previsão ingênua (último valor observado na origem), calculada nas mesmas origens.

MAE de teste e posição dentro de cada base


base	modelo	posição	MAE	MAE ingênuo	ganho sobre o ingênuo (%)	previsões
Brasil	Holt-Winters	1	2,645	3,818	30,7	33
Brasil	PLS	2	2,677	3,818	29,9	33
Brasil	SARIMAX	3	2,859	3,818	25,1	33
Brasil	Random Forest	4	2,905	3,818	23,9	33
Delhi	Holt-Winters	1	1,885	1,944	3,1	469
Delhi	PLS	2	1,981	1,944	-1,9	469
Delhi	Random Forest	3	2,021	1,944	-4,0	469
Delhi	SARIMAX	4	2,026	1,944	-4,2	469
Microsoft	SARIMAX	1	1,503	2,542	40,9	453
Microsoft	Random Forest	2	2,321	2,542	8,7	453
Microsoft	PLS	3	2,495	2,542	1,8	453
Microsoft	Holt-Winters	4	2,616	2,542	-2,9	453
Pilgrim's Pride	Holt-Winters	1	0,616	0,616	3,47e-08	2.925
Pilgrim's Pride	SARIMAX	2	0,617	0,616	-0,2	2.925
Pilgrim's Pride	PLS	3	0,829	0,616	-34,6	2.925
Pilgrim's Pride	Random Forest	4	0,862	0,616	-39,8	2.925
Sales	Random Forest	1	5.479,244	7.325,654	25,2	609
Sales	Holt-Winters	2	5.686,698	7.325,654	22,4	609
Sales	SARIMAX	3	5.720,228	7.325,654	21,9	609

base	modelo	posição	MAE	MAE ingênuo	ganho sobre o ingênuo (%)	previsões
Sales	PLS	4	5.974,187	7.325,654	18,4	609

Vitórias e posição média

modelo	vitórias	posição média	melhor posição	pior posição
Holt-Winters	3	1,8	1	4
SARIMAX	1	2,6	1	4
Random Forest	1	2,8	1	4
PLS	0	2,8	2	4

MAE de teste por base e modelo



Desempenho e características das bases

Delhi — série suave com ciclo anual forte e $h = 7$, em que o nível recente e o calendário explicam quase tudo. Ordem: Holt-Winters (1,885) < PLS (1,981) < Random Forest (2,021) < SARIMAX (2,026). Holt-Winters vence com vantagem de 5,1% sobre o 2º colocado e 3,1% sobre o ingênuo. Superam o ingênuo em mais de 0,5%: Holt-Winters.

Pilgrim's Pride — preço com tendência e mudanças de nível, sem sazonalidade útil e próximo de um passeio aleatório. Ordem: Holt-Winters (0,616) < SARIMAX (0,617) < PLS (0,829) < Random Forest (0,862). Holt-Winters vence com vantagem de 0,2% sobre o 2º colocado e praticamente o mesmo MAE do ingênuo. Nenhum modelo supera o ingênuo em mais de 0,5%: a série se comporta quase como um passeio aleatório.

Microsoft — abertura quase igual ao fechamento da sessão anterior, uma externa conhecida na origem. Ordem: SARIMAX (1,503) < Random Forest (2,321) < PLS (2,495) < Holt-Winters (2,616). SARIMAX vence com vantagem de 54,5% sobre o 2º colocado e 40,9% sobre o ingênuo. Superam o ingênuo em mais de 0,5%: SARIMAX, Random Forest e PLS.

Sales — lucro diário muito ruidoso, com crescimento, dias zerados e a lacuna de 2014. Ordem: Random Forest (5.479,244) < Holt-Winters (5.686,698) < SARIMAX (5.720,228) < PLS (5.974,187). Random Forest vence com vantagem de 3,8% sobre o 2º colocado e 25,2% sobre o ingênuo. Superam o ingênuo em mais de 0,5%: Random Forest, Holt-Winters, SARIMAX e PLS.

Brasil — contagem anual curta (109 anos), com muito ruído e ciclo fraco de Copa do Mundo. Ordem: Holt-Winters (2,645) < PLS (2,677) < SARIMAX (2,859) < Random Forest (2,905). Holt-Winters vence com vantagem de 1,2% sobre o 2º colocado e 30,7% sobre o ingênuo. Superam o ingênuo em mais de 0,5%: Holt-Winters, PLS, SARIMAX e Random Forest.

Padrões gerais: modelos que recebem as externas conhecidas na origem se destacam em Microsoft, onde o fechamento anterior é quase toda a informação; o Holt-Winters, univariado, é forte onde o alvo se parece com um passeio aleatório ou tem pouco sinal externo; o Random Forest tira proveito das relações não lineares e dos extremos de Sales; o PLS fica entre os melhores quando as features são numerosas e colineares, mas não acompanha níveis de preço fora da faixa do treino.

09 Análise dos resíduos e teste de Ljung-Box

Resíduo = observado – previsto, calculado fora da amostra. O teste de Ljung-Box tem como hipótese nula a ausência de autocorrelação até o lag avaliado: $p > 0,05$ significa não haver evidência de padrão remanescente, não prova de independência.

Há um cuidado metodológico para $h > 1$ (Delhi, Pilgrim's e Sales): os h erros de uma mesma origem são previsões feitas com a mesma informação e, por isso, correlacionados entre si por construção. A série agregada (passos 1 a h em ordem de data) tende a rejeitar ruído branco mesmo quando cada horizonte isolado não tem padrão. Por isso o teste é apresentado das duas formas: agregado, como pedido, e por passo de previsão, que é a leitura correta quando $h > 1$.

Ljung-Box agregado e por passo de previsão (20 combinações oficiais)

base	modelo	n	lags	viés (média)	desvio	estatística LB	p-valor agregado	ruído branco (agregado)	passos	passos com $p \leq 0,05$	menor p por passo
Brasil	Holt-Winters	33	6	0,133	3,587	7,5	0,2788	sim	1	0	0,2788
Brasil	PLS	33	6	1,035	3,504	7,8	0,2559	sim	1	0	0,2559
Brasil	Random Forest	33	6	1,165	3,834	8,6	0,1955	sim	1	0	0,1955
Brasil	SARIMAX	33	6	0,122	3,595	15,8	0,0148	não	1	1	0,0148
Delhi	Holt-Winters	469	10	0,002	2,503	293,9	3,02e-57	não	7	2	0,0046
Delhi	PLS	469	10	0,495	2,469	519,5	3,05e-105	não	7	1	0,0142
Delhi	Random Forest	469	10	0,953	2,315	425,8	3,06e-85	não	7	0	0,1032
Delhi	SARIMAX	469	10	-0,090	5,065	6,5	0,7737	sim	7	2	0,0004
Microsoft	Holt-Winters	453	10	0,135	3,638	16,8	0,0797	sim	1	0	0,0797
Microsoft	PLS	453	10	0,967	3,407	124,7	5,48e-22	não	1	1	5,48e-22
Microsoft	Random Forest	453	10	0,608	3,368	109,5	6,84e-19	não	1	1	6,84e-19
Microsoft	SARIMAX	453	10	-0,014	2,398	58,6	6,80e-09	não	1	1	6,80e-09
Pilgrim's Pride	Holt-Winters	2.925	10	-0,008	0,886	1.832,7	0,0000	não	5	0	0,0717
Pilgrim's Pride	PLS	2.925	10	0,037	1,170	3.743,3	0,0000	não	5	0	0,0548
Pilgrim's Pride	Random Forest	2.925	10	0,046	1,181	5.584,1	0,0000	não	5	5	9,62e-19
Pilgrim's Pride	SARIMAX	2.925	10	-0,008	0,887	1.843,4	0,0000	não	5	0	0,0569


base	modelo	n	lags	viés (média)	desvio	estatística LB	p-valor agregado	ruído branco (agregado)	passos	passos com $p \leq 0,05$	menor p por passo
Sales	Holt-Winters	609	10	171,079	8.500,650	137,6	1,32e-24	não	7	0	0,1028
Sales	PLS	609	10	551,602	8.742,841	305,4	1,10e-59	não	7	0	0,2026
Sales	Random Forest	609	10	1.689,252	7.962,880	128,5	9,33e-23	não	7	1	0,0396
Sales	SARIMAX	609	10	187,582	8.527,976	143,6	7,52e-26	não	7	0	0,0620

No teste agregado, 15 das 20 combinações rejeitam ruído branco. Nas bases com $h > 1$, 7 de 12 combinações não rejeitam em nenhum passo isolado, o que confirma que boa parte da rejeição agregada vem da correlação entre passos de uma mesma origem. Nas bases com $h = 1$, onde agregado e por passo coincidem, rejeitam: Brasil SARIMAX, Microsoft PLS, Microsoft Random Forest e Microsoft SARIMAX.

Em Microsoft, a rejeição indica padrão não capturado: em PLS e Random Forest o viés é positivo e a ACF de lag 1 também (0,30, 0,39): o erro persiste de um dia para o outro e as previsões ficam abaixo da alta da ação; em SARIMAX a ACF de lag 1 é negativa (-0,14), sinal de que a previsão reage demais ao movimento da sessão anterior.



Viés: valores positivos indicam subestimação (o observado fica acima do previsto). O viés supera 0,2 desvio-padrão em Brasil PLS, Brasil Random Forest, Delhi PLS, Delhi Random Forest, Microsoft PLS e Sales Random Forest; nos demais casos é pequeno frente à variabilidade do erro. Os gráficos abaixo mostram, para cada combinação, os resíduos no tempo e a ACF.

Delhi · SARIMAX





Delhi · SARIMAX

Delhi · Holt-Winters





Delhi · Holt-Winters

Delhi · Random Forest





Delhi · Random Forest

Delhi · PLS





Delhi · PLS

Pilgrim's Pride · SARIMAX





Pilgrim's Pride · SARIMAX

Pilgrim's Pride · Holt-Winters





Pilgrim's Pride · Holt-Winters

Pilgrim's Pride · Random Forest





Pilgrim's Pride · Random Forest

Pilgrim's Pride · PLS





Pilgrim's Pride · PLS

Microsoft · SARIMAX





Microsoft · SARIMAX

Microsoft · Holt-Winters





Microsoft · Holt-Winters

Microsoft · Random Forest





Microsoft · Random Forest

Microsoft · PLS




Microsoft · PLS

Sales · SARIMAX




Sales · SARIMAX

Sales · Holt-Winters




Sales · Holt-Winters

Sales · Random Forest




Sales · Random Forest

Sales · PLS





Sales · PLS

Brasil · SARIMAX





Brasil · SARIMAX

Brasil · Holt-Winters





Brasil · Holt-Winters

Brasil · Random Forest



Brasil · Random Forest

Brasil · PLS



Brasil · PLS

10 Importância das features

Cada modelo é interpretado pelo método compatível com ele. Random Forest: importância nativa (redução de impureza) e permutation importance. PLS: coeficientes na escala padronizada, VIP scores e permutation importance. SARIMAX: coeficientes das externas, com sinal, magnitude e significância. Holt-Winters: não tem features; interpreta-se o estado final de nível, tendência e sazonalidade. A permutation é medida na validação, com o modelo ajustado até o início dela, porque no treino um modelo que decorou os dados parece depender de tudo. Importância não implica causalidade.

Random Forest: 5 features de maior permutation importance por base

base	feature	tipo	disponibilidade	permutation	nativa
Brasil	desvio_8	interna	-	0,0615	0,1349
Brasil	desvio_4	interna	-	0,0588	0,0596
Brasil	matches_played_lag_1	externa	defasada	0,0416	0,0207
Brasil	friendly_matches_lag_1	externa	defasada	0,0334	0,0501
Brasil	lag_5	interna	-	0,0283	0,0314
Delhi	semana_cos	interna	-	0,2063	0,0819
Delhi	media_4	interna	-	0,1585	0,1579
Delhi	media_8	interna	-	0,0503	0,1163
Delhi	semana	interna	-	0,0388	0,0181
Delhi	wind_speed_lag_7	externa	defasada	0,0128	0,0036
Microsoft	close_lag_1	externa	conhecida	0,1957	0,3698
Microsoft	lag_1	interna	-	0,0266	0,1454
Microsoft	lag_2	interna	-	0,0051	0,0663
Microsoft	volume_lag_1	externa	conhecida	0,0045	0,0002
Microsoft	desvio_4	interna	-	0,0006	0,0002
Pilgrim's Pride	lag_5	interna	-	0,6959	0,1306
Pilgrim's Pride	Low_lag_5	externa	defasada	0,6664	0,1360
Pilgrim's Pride	media_4	interna	-	0,6075	0,1335

base	feature	tipo	disponibilidade	permutation	nativa
Pilgrim's Pride	media_12	interna	-	0,4926	0,1496
Pilgrim's Pride	media_8	interna	-	0,4759	0,1249
Sales	media_12	interna	-	1.597,0125	0,1473
Sales	media_8	interna	-	1.340,5505	0,1351
Sales	transaction_count_lag_7	externa	defasada	988,1563	0,0953
Sales	media_4	interna	-	942,8110	0,1000
Sales	lag_10	interna	-	475,3915	0,0603

PLS: 5 features de maior permutation importance por base

base	feature	tipo	disponibilidade	permutation	vip	coeficiente padronizado
Brasil	desvio_8	interna	-	0,0411	1,51	0,337
Brasil	lag_4	interna	-	0,0222	1,23	0,274
Brasil	desvio_12	interna	-	0,0200	1,51	0,336
Brasil	media_12	interna	-	0,0038	1,40	0,312
Brasil	desvio_4	interna	-	-0,0007	1,08	0,240
Delhi	semana_cos	interna	-	1,2014	1,42	-2,276
Delhi	media_12	interna	-	0,9994	1,43	2,479
Delhi	mes_cos	interna	-	0,5170	1,35	-1,426
Delhi	semana_sin	interna	-	0,5130	0,47	-1,335
Delhi	mes_sin	interna	-	0,4170	0,62	1,103
Microsoft	lag_1	interna	-	1,6302	1,53	4,553
Microsoft	close_lag_1	externa	conhecida	0,1902	1,53	9,108
Microsoft	lag_2	interna	-	0,1628	1,53	0,914
Microsoft	semana	interna	-	0,0642	0,17	0,609
Microsoft	lag_30	interna	-	0,0370	1,48	0,304

base	feature	tipo	disponibilidade	permutation	vip	coeficiente padronizado
Pilgrim's Pride	lag_5	interna	-	5,8782	1,51	4,605
Pilgrim's Pride	Low_lag_5	externa	defasada	0,8978	1,51	0,929
Pilgrim's Pride	media_8	interna	-	0,6413	1,50	0,709
Pilgrim's Pride	lag_6	interna	-	0,2754	1,50	-0,421
Pilgrim's Pride	media_12	interna	-	0,0867	1,50	-0,220
Sales	transaction_count_lag_7	externa	defasada	3.875,6264	1,63	2.361,542
Sales	media_12	interna	-	2.024,8367	1,54	953,631
Sales	media_8	interna	-	1.617,7574	1,54	802,856
Sales	desvio_12	interna	-	539,9463	1,07	612,870
Sales	lag_10	interna	-	181,3098	1,17	143,666


Quanto da importância (permutation positiva) vem das variáveis externas

base	modelo	% da importância nas externas	externa mais importante	posição dela no ranking
Brasil	PLS	0,0	friendly_matches_lag_1	12
Brasil	Random Forest	21,8	matches_played_lag_1	3
Delhi	PLS	8,6	meanpressure_lag_7	6
Delhi	Random Forest	2,9	wind_speed_lag_7	5
Microsoft	PLS	8,9	close_lag_1	2
Microsoft	Random Forest	85,4	close_lag_1	1
Pilgrim's Pride	PLS	11,4	Low_lag_5	2
Pilgrim's Pride	Random Forest	17,7	Low_lag_5	2
Sales	PLS	44,6	transaction_count_lag_7	1
Sales	Random Forest	15,6	transaction_count_lag_7	3

As externas ganham espaço onde trazem informação que os lags do alvo não têm e que está disponível na origem. Em Microsoft, `close_lag_1` é conhecida na origem (é o fechamento de ontem) e por isso pode entrar sem defasagem extra. Em Sales, `transaction_count_lag_7` é uma externa defasada em $h = 7$, porque o número de transações do dia

só é conhecido depois que o dia termina. Em Delhi e Pilgrim's, as externas entram defasadas em h e carregam pouco além do que os próprios lags do alvo já informam.

Permutation importance na validação (dourado = variável externa)



Permutation importance (RF e PLS)

SARIMAX: coeficientes das externas no ajuste até o fim da validação

base	exogena	disponibilidade	coeficiente	sinal	erro_padrao	p_valor	significativa
Delhi	humidity_lag_7	defasada	0,00181	positivo	0,00593	0,7597	não
Delhi	wind_speed_lag_7	defasada	0,00602	positivo	0,01167	0,6059	não
Delhi	meanpressure_lag_7	defasada	0,01358	positivo	0,02653	0,6086	não
Pilgrim's Pride	Low_lag_5	defasada	-0,01965	negativo	0,00871	0,0240	sim
Pilgrim's Pride	Volume_lag_5	defasada	-5,90e-09	negativo	4,45e-09	0,1846	não

base	exogena	disponibilidade	coeficiente	sinal	erro_padrao	p_valor	significativa
Microsoft	close_lag_1	conhecida	1,00064	positivo	0,00050	0,0000	sim
Microsoft	volume_lag_1	conhecida	6,40e-10	positivo	1,12e-09	0,5682	não
Sales	transaction_count_lag_7	defasada	-26,78156	negativo	6,74473	7,16e-05	sim
Brasil	matches_played_lag_1	defasada	-0,39180	negativo	0,19086	0,0401	sim
Brasil	friendly_matches_lag_1	defasada	0,10359	positivo	0,21257	0,6260	não

Holt-Winters: estado final (nível, tendência e amplitude sazonal)

base	nivel_final	tendencia_final	amplitude_sazonal	amplitude_sobre_nivel_pct	trend	seasonal	damped
Delhi	15,874	2,25e-07	—	—	add	—	sim
Pilgrim's Pride	21,278	—	—	—	—	—	não
Microsoft	144,823	0,094	0,018	0,0	add	mul	não
Sales	3,13e-08	—	—	—	—	—	não
Brasil	7,710	—	2,718	35,3	—	add	não

11 Explicação aprofundada do modelo escolhido

Intuição

O PLS Regression (Partial Least Squares) resume muitas features correlacionadas em poucos componentes latentes e faz a regressão nesse espaço reduzido. A diferença para o PCA está em como os componentes são escolhidos: o PCA busca as direções de maior variância de X, sem olhar o alvo; o PLS busca as direções de X com maior covariância com y. Os componentes são, portanto, supervisionados: um componente que explica muita variância de X mas nada de y é irrelevante para o PLS.

Isso combina com séries temporais: lags, médias e desvios móveis da mesma série são fortemente correlacionados entre si, e uma regressão linear comum sobre eles teria coeficientes instáveis. O PLS concentra essa informação compartilhada em poucas direções úteis para prever.

Como o algoritmo funciona (NIPALS, um alvo)

Com X e y centralizados: (1) o peso w é a direção de X com maior covariância com y, proporcional a XY^T ; (2) o score $t = Xw$ é a projeção das observações nessa direção; (3) y é regredido em t, e X é 'deflacionado', removendo a parte explicada por t. O passo se repete para o próximo componente sobre o que sobrou. Com um único alvo (PLS1), cada componente converge em uma iteração, o que o pipeline confere pelo `n_iter_`. A previsão final é uma combinação linear das features originais.

Hipóteses, vantagens, limitações e preparação


Vantagens: tolera multicolinearidade, funciona com muitas features e é interpretável por coeficientes e VIP. Hipóteses e limitações: a relação é linear no espaço latente, então interações e descontinuidades não são aprendidas como numa floresta; é sensível à escala e a outliers; e, por ser linear, extrapola níveis fora da faixa do treino com os mesmos pesos, o que pesa em séries de preço com mudança de patamar. Preparação: padronização das features em cada janela (`StandardScaler` , com `PLSRegression(scale=False)` para não padronizar duas vezes) e tratamento das externas extremas.

Dois ajustes próprios do grupo, aprendidos só no treino: **(1) remoção de redundâncias exatas** — `media_4` é a média de `lag_h ... lag_h+3` e `delta_nivel = media_4 - media_12`; no Brasil, `semana_cos` é constante em função de `semana_sin` na série anual. Removidas: `delta_nivel`, `media_4`, `semana_cos`. Sem isso, o posto de X fica abaixo do número de colunas e componentes além do posto ajustam erro de arredondamento. **(2) Winsorização só das externas** nos quantis de 0,5% e 99,5% do treino de cada origem, para conter erros de medição como as pressões impossíveis de Delhi. Lags e janelas do alvo não são limitados, para o modelo acompanhar níveis novos.

Hiperparâmetros, efeito e otimização

O hiperparâmetro principal é `n_components`: poucos componentes subajustam (o modelo vira uma média suavizada das features); muitos reincorporam ruído e aproximam o PLS de uma regressão comum sobre todas as features. A grade testa todos os valores de 1 até o menor entre 30, o posto de X e o tamanho da menor janela de treino menos 1, e vence o

menor MAE walk-forward na validação. `max_iter` = 500 e `tol` = 1e-6 só controlam a convergência e não precisam de busca no PLS1.



Escolhas: Delhi escolheu 20 de 23; Pilgrim's Pride escolheu 19 de 20; Microsoft escolheu 13 de 22; Sales escolheu 5 de 21; Brasil escolheu 1 de 17. Sales e Brasil, as séries mais ruidosas, ficaram com poucos componentes (forte redução de dimensão funciona como regularização); nas demais, a curva cai até algo entre 10 e 20 componentes e depois fica plana.

Importância das features no PLS

O VIP (Variable Importance in Projection) mede quanto cada feature pesa na construção dos componentes, ponderado pelo quanto cada componente explica de y ; $VIP \geq 1$ é a referência usual de relevância. O coeficiente padronizado dá a direção e o tamanho do efeito na previsão. A permutation importance mede quanto o MAE de validação piora ao embaralhar a feature. As medidas discordam de forma informativa: uma feature pode ter VIP alto e permutation baixa quando a mesma informação está numa feature irmã.

Delhi: maior VIP `media_8` (1,44), maior permutation `semana_cos`; externas com $VIP \geq 1$: `meanpressure_lag_7`. Pilgrim's Pride: maior VIP `lag_5` (1,51), maior permutation `lag_5`; externas com $VIP \geq 1$: `Low_lag_5`, `Volume_lag_5`. Microsoft: maior VIP `close_lag_1` (1,53), maior permutation `lag_1`; externas com $VIP \geq 1$: `close_lag_1`. Sales: maior VIP `transaction_count_lag_7` (1,63), maior permutation `transaction_count_lag_7`; externas com $VIP \geq 1$: `transaction_count_lag_7`. Brasil: maior VIP `desvio_8` (1,51), maior permutation `desvio_8`; externas com $VIP \geq 1$: nenhuma.

Desempenho nas cinco bases

PLS por base (MAE / ingênuo < 1 = melhor que repetir o último valor)

base	componentes	features	MAE validação	MAE teste	MAE / ingênuo	posição (de 4)	Ljung-Box: passos com $p \leq 0,05$
Delhi	20	23	1,916	1,981	1,02	2	1 de 7
Pilgrim's Pride	19	20	0,497	0,829	1,35	3	0 de 5

base	componentes	features	MAE validação	MAE teste	MAE / ingênuo	posição (de 4)	Ljung-Box: passos com $p \leq 0,05$
Microsoft	13	22	1,195	2,495	0,98	3	1 de 1
Sales	5	21	4.791,286	5.974,187	0,82	4	0 de 7
Brasil	1	17	2,837	2,677	0,70	2	0 de 1

Explicações: o PLS ganha do ingênuo onde o alvo é ruidoso e pouco persistente — Sales (18% melhor) e Brasil (30%) —, porque as médias móveis funcionam como encolhimento do ruído. Em Microsoft e Delhi fica praticamente empatado com o ingênuo (razões 0,98 e 1,02): o último valor já é quase toda a informação. Em Pilgrim's perde (1,35): os pesos de sinais opostos nos lags foram aprendidos em níveis de preço baixos e amplificam o ruído no teste, onde o preço é várias vezes maior. Em Microsoft, o Ljung-Box ainda indica padrão residual; uma causa plausível é a winsorização de `close_lag_1`, que é um nível de preço e passa a ser limitado quando a ação supera a faixa do treino.

Histórico e transparência

A primeira versão do PLS previu 1.252,94 °C em Delhi para 2016-04-04, uma data do teste, por causa das pressões impossíveis da base. Uma ablação posterior mostrou que, sem a limitação da grade ao posto de X, Pilgrim's e Microsoft explodiam, e que limitar também os lags do alvo gerava viés nas séries de preço. A versão final remove as redundâncias exatas e winsoriza só as externas. Como essas correções foram motivadas por erros observados no teste, os MAEs de teste do PLS não são estimativas totalmente intocadas; a documentação completa está em `DOCUMENTACAO_PLS.md`.

12 Conclusões, limitações e recomendações

Conclusões. Nenhum modelo domina: **SARIMAX** venceu Microsoft; **Holt-Winters** venceu Brasil, Delhi e Pilgrim's Pride; **Random Forest** venceu Sales. No placar, Holt-Winters lidera com 3 vitórias e posição média 1,8. O Holt-Winters, mesmo sem externas, venceu 3 bases: é uma referência difícil de bater em séries persistentes. As externas só fazem diferença quando são conhecidas na origem e trazem informação nova, como em Microsoft. O PLS entregou o que promete — estabilidade sob features colineares e interpretabilidade —, mas não superou modelos especializados em nenhuma base.

Limitações. (1) Sales: a lacuna de cinco meses virou lucro zero e afeta o fim da validação e o início do teste; as linhas idênticas da fonte foram somadas como transações. Os resultados de Sales devem ser lidos com essa ressalva. (2) Delhi: o SARIMAX usa as externas sem tratamento e previu 129,7 °C para 04/04/2016 (observado: 32,8 °C), porque a pressão defasada dessa data é 7.679,3 hPa, fisicamente impossível; sem essa origem, o MAE dele cairia de 2,026 para 1,820. As posições de Delhi refletem essa diferença de tratamento das externas entre os modelos. (3) Para limitar o custo do SARIMAX, $m \leq 30$; o ciclo anual de Delhi e o de 252 pregões das ações ficam só nas features de calendário. (4) O Ljung-Box agregado rejeita por construção quando $h > 1$; o diagnóstico por passo é o que vale para essas bases. (5) A winsorização do PLS foi decidida após observar um erro no teste. (6) Não foi possível confirmar na fonte se os preços da Pilgrim's Pride são ajustados por dividendos e desdobramentos. (7) Random Forest e Holt-Winters podem variar levemente com a versão de scikit-learn e statsmodels; as versões usadas estão em `requirements.txt`.

Recomendações. Selecionar o modelo por base, não um único para todas; monitorar MAE por horizonte, viés e Ljung-Box por passo; tratar na origem as lacunas de Sales (como ausência de dado, não como zero) e as pressões impossíveis de Delhi; recalibrar quando a degradação for sustentada, e não por um ponto isolado; e, se os intervalos do Kalman forem usados, calibrá-los antes (seção 14).

Base Delhi: <https://www.kaggle.com/datasets/sumanthvrao/daily-climate-time-series-data>

Base Pilgrim's Pride: <https://www.kaggle.com/datasets/mandalorianforza/pilgrims-pride-ppc-daily-stock-price-history>

Base Microsoft: <https://www.kaggle.com/datasets/vijayvvenkitesh/microsoft-stock-time-series-analysis>

Base Sales: <https://www.kaggle.com/datasets/sadiqshah/bike-sales-in-europe>

Base Brasil: <https://www.kaggle.com/datasets/azminetoushikwasi/brazil-all-international-matches-19142023>

Hyndman, R. J.; Athanasopoulos, G. Forecasting: Principles and Practice, 3rd ed. OTexts, 2021. <https://otexts.com/fpp3/>

Cleveland, R. B. et al. STL: A Seasonal-Trend Decomposition Procedure Based on Loess. *Journal of Official Statistics*, 6(1), 3–73, 1990.

Ljung, G. M.; Box, G. E. P. On a Measure of Lack of Fit in Time Series Models. *Biometrika*, 65(2), 297–303, 1978. <https://doi.org/10.1093/biomet/65.2.297>

Geladi, P.; Kowalski, B. R. Partial least-squares regression: a tutorial. *Analytica Chimica Acta*, 185, 1–17, 1986. [https://doi.org/10.1016/0003-2670\(86\)80028-9](https://doi.org/10.1016/0003-2670(86)80028-9)

Wold, S.; Sjöström, M.; Eriksson, L. PLS-regression: a basic tool of chemometrics. *Chemometrics and Intelligent Laboratory Systems*, 58, 109–130, 2001. [https://doi.org/10.1016/S0169-7439\(01\)00155-1](https://doi.org/10.1016/S0169-7439(01)00155-1)

Breiman, L. Random Forests. *Machine Learning*, 45, 5–32, 2001.

statsmodels: STL, SARIMAX, ExponentialSmoothing e `acorr_ljungbox`. <https://www.statsmodels.org/stable/tsa.html>

scikit-learn: PLSRegression, RandomForestRegressor e `permutation_importance`. https://scikit-learn.org/stable/modules/cross_decomposition.html ; https://scikit-learn.org/stable/modules/permutation_importance.html

Enunciado do trabalho: `n2_series_temporais.pdf`. Código: `prepare_bases.ipynb` e `pipeline.ipynb`; artefatos em `resultados/`.

14 Apêndices técnicos e registro de demandas

Bônus: regressão dinâmica com filtro de Kalman

O Kalman estima coeficientes que mudam no tempo ($y_t = x_t^T \beta_t + \varepsilon_t$, $\beta_t = \beta_{t-1} + \eta_t$), com a sequência causal prever $\rightarrow$ atualizar e sem atualização dentro do horizonte futuro. Q e R são escolhidos na validação. Ele produz intervalos de previsão; a cobertura observada mostra se são confiáveis.

Configurações bônus (fora do placar)

base	modelo	MAE	ganho sobre o ingênuo (%)	MAE do melhor oficial
Brasil	Kalman	3,276	14,2	2,645
Delhi	Kalman	1,930	0,7	1,885
Microsoft	Kalman Fourier+ACF m=176	2,175	14,4	1,503
Microsoft	Kalman	2,204	13,3	1,503
Microsoft	Random Forest Fourier+ACF m=176	2,341	7,9	1,503
Microsoft	PLS Fourier+ACF m=176	2,415	5,0	1,503
Pilgrim's Pride	PLS Fourier+ACF m=2275	0,830	-34,8	0,616
Pilgrim's Pride	Random Forest Fourier+ACF m=2275	0,849	-37,8	0,616
Pilgrim's Pride	Kalman Fourier+ACF m=2275	0,871	-41,3	0,616
Pilgrim's Pride	Kalman	0,886	-43,8	0,616
Sales	Kalman	6.496,099	11,3	5.479,244

Kalman: cobertura dos intervalos no teste

base	cobertura 80% (nominal 80)	cobertura 95% (nominal 95)	largura média do intervalo 95%
Brasil	93,9	100,0	23,80
Delhi	94,2	98,3	14,14
Microsoft	60,7	77,0	5,78
Pilgrim's Pride	74,8	89,3	3,66

base	cobertura 80% (nominal 80)	cobertura 95% (nominal 95)	largura média do intervalo 95%
Sales	86,0	94,7	34.515,96

Bônus: investigação sazonal por Fourier + ACF

Picos do espectro de Fourier e da ACF propõem períodos candidatos; a força STL escolhe entre eles. Um período alternativo só vira configuração bônus quando ganha pelo menos 0,05 de força sobre o padrão. Ganho de força não garante ganho de previsão: em Pilgrim's, m = 2275 (cerca de 9 anos, só 3 ciclos) provavelmente captura tendência e não um ciclo real.

Períodos investigados

base	m padrão	candidato	ganho de força	m efetivo	decisão
Delhi	30	36	0,039	30	ganho_sazonal_0.039016_abaixo_de_0.05
Pilgrim's Pride	1	2.275	0,572	2.275	ganho_sazonal_aprovado
Microsoft	30	176	0,430	176	ganho_sazonal_aprovado
Sales	12	11	0,033	12	ganho_sazonal_0.032941_abaixo_de_0.05
Brasil	4	4	0,000	4	mesmo_periodo_padrao

Sales: distribuição por partição

Lucro diário de Sales em treino, validação e teste

particao	n	media	mediana	desvio	iqr	p90	p95	p99	maximo	zeros	outliers_iqr
treino	999	8.729,8	7.253,0	6.075,5	6.183,5	15.529,2	20.961,7	30.604,5	43.617,0	1	52
validacao	428	20.877,4	25.224,0	15.471,3	32.430,5	38.798,5	43.107,7	49.220,1	59.253,0	119	0
teste	612	23.798,2	24.834,0	16.411,9	28.368,5	44.710,0	50.862,0	60.035,2	72.218,0	35	0

Reprodutibilidade

Os resultados são reproduzíveis a partir dos arquivos entregues: `prepare_bases.ipynb` gera as bases; `pipeline.ipynb` , executado do início ao fim, reaproveita os checkpoints de `resultados/checkpoints_final/` (ou refaz tudo com `rodar(bases, refazer=True)` , cerca de 3 horas) e esta última célula gera Markdown, HTML e PDF a partir dos CSVs. Instruções e versões das bibliotecas estão em `README.md` e `requirements.txt` .

Uso de IA: o grupo usou ferramentas de IA como apoio à implementação, à revisão e à redação. Código, resultados e interpretações foram revisados criticamente pelos integrantes, que assumem a responsabilidade integral pelo conteúdo.

Registro diário de demandas

Registro de demandas (relatorio/registro_demandas.csv)

Data	Integrante	Demanda realizada	Entrega ou evidência	Carga de trabalho	Complexidade	Status
10/09/2026	Fernando Paiva	Organização geral do projeto	relato do integrante (sem arquivo)	Baixa	Baixa	Concluída
10/09/2026	Giovanna Pelati	Organização geral do projeto	relato do integrante (sem arquivo)	Baixa	Baixa	Concluída
10/09/2026	João Vargas	Organização geral do projeto	relato do integrante (sem arquivo)	Baixa	Baixa	Concluída
10/09/2026	Matheus Cury	Organização geral do projeto	relato do integrante (sem arquivo)	Baixa	Baixa	Concluída
10/09/2026	Sophia Gasparetto	Organização geral e pesquisa das bases	relato do integrante (sem arquivo)	Baixa	Baixa	Concluída
15/09/2026	Sophia Gasparetto	Criação do repositório e inclusão das bases brutas	commits 6570257 e b977dc5; bases/raw/	Baixa	Baixa	Concluída
15/09/2026	Matheus Cury	Estrutura inicial do pipeline.ipynb (leitura das bases e esqueleto das etapas)	commit d8372a1; pipeline.ipynb	Média	Média	Concluída
15/09/2026	Fernando Paiva	Definição das especificações e das bases	relato do integrante (sem arquivo)	Média	Média	Concluída
15/09/2026	João Vargas	Estudo e documentação do projeto	relato do integrante (sem arquivo)	Média	Baixa	Concluída
17/09/2026	Matheus Cury	Regras fixas do grupo: random_state=42 e separação 70-30 em treino/validação/teste	commit 110802c; pipeline.ipynb (seções 0 e 1)	Baixa	Baixa	Concluída
17/09/2026	Matheus Cury	Seleção do SARIMAX por BIC com desempate por MAE de validação	commit 24a7206; pipeline.ipynb (seção 3.5)	Média	Média	Concluída
17/09/2026	Matheus Cury	Escolha do período sazonal m pela força da STL em vez de m fixo	commit 4d5fb42; pipeline.ipynb (seção 2.3)	Média	Média	Concluída
17/09/2026	Sophia Gasparetto	Notebook reprodutível de preparação das cinco bases	commit 6a597fc; prepare_bases.ipynb; bases/*_prepared.csv	Alta	Média	Concluída
17/09/2026	Fernando Paiva	Adição de elementos na pipeline padrão	relato do integrante; pipeline.ipynb	Média	Média	Concluída

Data	Integrante	Demanda realizada	Entrega ou evidência	Carga de trabalho	Complexidade	Status
17/09/2026	João Vargas	Base do relatório e entendimento da pipeline	relato do integrante (sem arquivo)	Média	Baixa	Concluída
22/09/2026	Sophia Gasparetto	Correção da preparação das bases Brasil e Sales	commit 25dd002; bases/brazil_prepared.csv; bases/sales_prepared.csv	Média	Média	Concluída
22/09/2026	Matheus Cury	Registro das cinco bases no pipeline com horizonte e exógenas	commit 9bb436d; pipeline.ipynb (seção 1)	Média	Média	Concluída
22/09/2026	Giovanna Pelati	Revisão da pipeline e início da implementação do modelo de especialização	relato do integrante; pipeline.ipynb	Média	Média	Concluída
24/09/2026	Matheus Cury	Análise prévia completa (STL; ADF/KPSS; VIF) e correção do mapeamento das exógenas	commit 42c20ab; resultados/decisoies_analise.csv; resultados/disponibilidade_exogenas.csv	Alta	Alta	Concluída
24/09/2026	Matheus Cury	Importância das features (RF nativa e permutation; PLS; coeficientes SARIMAX; estado Holt-Winters)	commit f0bbcec; resultados/importancia_features.csv	Média	Média	Concluída
24/09/2026	Matheus Cury	Primeira rodada de treino dos modelos	commit ab660c4; pipeline.ipynb	Média	Média	Concluída
24/09/2026	Giovanna Pelati	Estudo e documentação do PLS	relato do integrante; DOCUMENTACAO_PLS.md (versionado no commit f494704)	Média	Alta	Concluída
25/09/2026	Matheus Cury	Rodada completa do pipeline (5 bases x 4 modelos) com caches do SARIMAX	commit fc30f94; resultados/previsoes.csv; resultados/hiperparametros.csv	Alta	Média	Concluída
27/09/2026	João Vargas	Primeira versão do relatório (Markdown; HTML; PDF) e tabelas de MAE e Ljung-Box	commit ee95811; relatorio/RELATORIO.md; relatorio/relatorio.html; relatorio/relatorio.pdf	Alta	Média	Concluída
28/09/2026	Giovanna Pelati	Implementação do PLS (remoção de redundâncias; winsorização das externas; grade até o posto de X; VIP)	commits f494704 e 8b9cf34; pipeline.ipynb (seções 3.8 e 4.6); DOCUMENTACAO_PLS.md	Alta	Alta	Concluída
29/09/2026	Sophia Gasparetto	Exploração aprofundada das bases (item 5.1): estatísticas; checagens de consistência; painéis	commit 4e042e6; relatorio/item_5_1_documentacao_exploracao.md; resultados/item_5_1/	Alta	Média	Concluída
01/10/2026	Matheus Cury	Bônus Kalman e Fourier+ACF; checkpoints; gerador do relatório; consolidação dos artefatos	commit 6baec99; pipeline.ipynb (seções 2.3B; 3.9; 3.10; 5)	Alta	Alta	Concluída
04/10/2026	Giovanna Pelati	Revisão final: reexecução isolada dos notebooks e verificação de reprodutibilidade das 31 configurações	reexecução dos notebooks em cópia isolada; comparação das previsões com resultados/previsoes.csv	Alta	Alta	Concluída
05/10/2026	Giovanna Pelati	Correção da divergência código x resultados (SARIMAX sem winsorização; Kalman refeito); limpeza do repositório; relatório final	pipeline.ipynb; resultados/; relatorio/; README.md	Alta	Alta	Concluída